

MEMORIA

Predicción de la Rotación de Personal mediante Machine Learning para la Retención Estratégica del Talento

De la exploración de factores psicosociales a un modelo predictivo
interpretable aplicado a People Analytics

Autora: Susana Pérez Barroeta

Fecha: 16 de enero de 2026

Contenido

Introducción y contexto del proyecto.....	3
Objetivos del Proyecto.....	3
Objetivo principal.....	3
Objetivo secundario.....	3
Obtención y descripción de los datos.....	4
Dataset utilizado.....	4
Análisis Exploratorio de Datos (EDA).....	4
Preprocesamiento y Feature Engineering.....	5
Definición del problema de Machine Learning.....	6
Modelado.....	6
Selección e interpretación del modelo final.....	8
Extracción de datos y predicción.....	10
Demo y aplicación práctica.....	10
Acciones previstas según nivel de riesgo.....	10
Limitaciones y futuros pasos.....	11
Conclusión.....	11

Introducción y contexto del proyecto

La rotación de personal representa un reto estratégico para las organizaciones debido a su impacto directo en costes de selección, formación, pérdida de conocimiento y estabilidad de los equipos. En el ámbito de People Analytics, este problema ha sido abordado tradicionalmente desde análisis descriptivos que permiten identificar factores asociados al abandono, pero que no facilitan la anticipación ni la priorización de acciones preventivas.

Este proyecto aborda la rotación de personal desde un enfoque de People Analytics, partiendo de un análisis exploratorio previo centrado en factores psicosociales como la satisfacción laboral, el bienestar, el compromiso y la cultura organizacional. A partir de este análisis, se desarrolla un modelo de Machine Learning capaz de predecir la probabilidad individual de abandono, con el objetivo de apoyar la toma de decisiones estratégicas en Recursos Humanos.

El valor añadido del proyecto reside en la transformación de un análisis descriptivo en una herramienta predictiva aplicable a entornos reales, manteniendo un equilibrio entre capacidad predictiva, interpretabilidad y alineación con el impacto en negocio.

Objetivos del Proyecto

Objetivo principal

Desarrollar y evaluar un modelo de Machine Learning capaz de predecir la probabilidad de rotación del personal a partir de variables demográficas, laborales y psicosociales, con el fin de anticipar el abandono del talento y apoyar la toma de decisiones estratégicas en el área de Recursos Humanos.

Objetivo secundario

- Construir un modelo que estime la probabilidad de que una persona abandone la empresa.
- Probar y comparar diferentes modelos de Machine Learning para identificar el que mejor predice la rotación.
- Analizar qué variables influyen más en el riesgo de abandono para facilitar la interpretación de las predicciones.
- Utilizar los resultados del modelo para proponer acciones orientadas a la reducción de la rotación del personal.

Obtención y descripción de los datos

Dataset utilizado

El dataset empleado es **IBM HR Analytics: Employee Attrition & Performance**, disponible públicamente en la plataforma Kaggle.

El conjunto de datos contiene información anonimizada de **1.470 empleados**, con un total de **35 variables**, incluyendo características demográficas, laborales, de satisfacción y desempeño, así como una variable objetivo binaria que indica si la persona abandonó o no la empresa (Attrition).

La tasa de rotación del dataset es aproximadamente del **16%**, lo que introduce un desbalance significativo entre clases.

Versiones del dataset

A lo largo del proyecto se trabajó con distintas versiones del conjunto de datos:

- **Dataset original:** descargado directamente desde Kaggle, sin modificaciones.
- **Dataset limpio:** versión depurada tras eliminar columnas irrelevantes, verificar valores nulos y duplicados, y estandarizar formatos.
- **Dataset procesado para Machine Learning:** versión final que incluye variables transformadas, codificadas y nuevas variables creadas mediante feature engineering.

Esta última versión es la utilizada para el entrenamiento y evaluación de los modelos.

Análisis Exploratorio de Datos (EDA)

El análisis exploratorio permitió identificar patrones relevantes que justifican el uso de Machine Learning:

- La rotación no se distribuye de forma aleatoria.
- La realización de horas extra incrementa notablemente la probabilidad de abandono.
- Variables relacionadas con el bienestar psicológico y el engagement muestran una fuerte asociación con la rotación.
- Una cultura organizacional positiva actúa como factor protector.

Estos hallazgos sirvieron como base para la selección de variables y la posterior creación de nuevas features.

Preprocesamiento y Feature Engineering

Preprocesamiento

Antes del modelado se realizaron las siguientes tareas:

- Verificación de calidad de los datos (ausencia de valores nulos y duplicados).
- Eliminación de variables irrelevantes o redundantes.
- Las variables categóricas se transformaron mediante One-Hot Encoding, generando variables dummy binarias. Se utilizó el parámetro `drop='first'`, eliminando la primera categoría de cada variable categórica, con el objetivo de:
 - o Evitar problemas de multicolinealidad, especialmente relevantes en modelos lineales como la Regresión Logística.
 - o Reducir la dimensionalidad del dataset sin pérdida de información relevante.
- Transformación de variables ordinales respetando su escala original.
- División estratificada en conjuntos de entrenamiento y test.

Con el fin de garantizar coherencia y reproducibilidad entre los distintos notebooks del proyecto, se almacenaron metadatos relacionados con la clasificación de variables (continuas, ordinales, binarias, categóricas y variables proxy). Estos metadatos fueron reutilizados en los notebooks posteriores durante el proceso de preparación de datos y modelado, evitando reclasificaciones manuales y asegurando consistencia en las transformaciones aplicadas.

Dado el desbalance existente en la variable objetivo (aproximadamente un 16% de rotación), se realizó una división estratificada en los conjuntos de entrenamiento y test, garantizando que ambos mantuvieran la misma proporción de empleados que abandonan y que permanecen en la empresa.

Los valores extremos se mantuvieron al considerarse informativos en un contexto real de RRHH.

Feature Engineering

Se crearon variables proxy para representar constructos no medidos directamente en el dataset original:

- BurnoutRisk
- CulturaPositiva
- AltoEngagement
- OportunidadesDesarrollo

Estas variables permiten capturar dimensiones psicosociales relevantes, mejorando tanto el rendimiento predictivo como la interpretación del modelo.

Definición del problema de Machine Learning

El problema se planteó como una clasificación supervisada binaria, donde el objetivo es predecir si un empleado abandonará la empresa (Attrition = 1) o no (Attrition = 0).

Dado el fuerte impacto económico y organizativo de la pérdida de talento, se priorizó la detección temprana de empleados en riesgo, incluso a costa de reducir la precisión absoluta del modelo.

No detectar a tiempo una baja real (falso negativo) implica costes elevados en términos de reclutamiento, formación y pérdida de conocimiento, mientras que una intervención innecesaria (falso positivo) supone un coste relativamente bajo.

Modelado

Proceso de modelado y validación

El proceso de modelado se desarrolló de forma iterativa, siguiendo los siguientes pasos:

1. **Entrenamiento inicial de modelos base:** Se entrenaron pipelines iniciales de Regresión Logística, Random Forest y XGBoost. Los modelos basados en árboles mostraron una accuracy cercana a 1.00 en entrenamiento, indicando un claro sobreajuste.
2. **Uso de validación cruzada:** Se aplicó cross-validation para estimar el rendimiento real y reducir la dependencia de una única partición train-test. Los resultados confirmaron que los modelos basados en árboles no generalizaban adecuadamente.
3. **Optimización de hiperparámetros:** Se aplicaron técnicas de búsqueda de hiperparámetros (GridSearch y RandomSearch). XGBoost mostró el mejor equilibrio en validación cruzada.
4. **Evaluación en conjunto de test:** Al evaluar XGBoost en test, el recall cayó significativamente, evidenciando un problema de sobreajuste.

5. **Selección de Random Forest:** Random Forest mostró un comportamiento ligeramente mejor en test, detectando un caso adicional de abandono (Recall 48.9% vs 46.8%).
6. **Ajuste del umbral de decisión:** Dado que la prioridad era maximizar la detección temprana, se ajustó el umbral de decisión, analizando explícitamente el trade-off entre recall, precisión y carga operativa del sistema.

Esta evolución - de un XGBoost sobreajustado a un Random Forest robusto con umbral ajustado - refleja el rigor de la validación en datos no vistos y la priorización del impacto en negocio sobre el rendimiento aparente en entrenamiento.

Para abordar el desbalance de clases, se aplicaron distintas estrategias según el tipo de modelo:

- Regresión Logística:
 - o Escalado de variables continuas mediante ColumnTransformer.
 - o Uso de `class_weight='balanced'` para penalizar más los errores en la clase minoritaria.
- Random Forest:
 - o Uso de `class_weight='balanced'`, ajustando el peso de cada clase durante el entrenamiento de los árboles.
- XGBoost:
 - o Ajuste del parámetro `scale_pos_weight`, calculado como la ratio entre observaciones negativas y positivas, para compensar el desbalance durante el boosting.

La evaluación se realizó utilizando métricas adecuadas a un problema desbalanceado:

- **Recall** que mide, de todos los empleados que realmente se van, cuántos consigue detectar el modelo.
- **Precision** que mide, de todos los empleados que el modelo marca como “se van”, cuántos realmente se van.
- **F1-score** que mide el equilibrio entre recall y precisión; es una media que solo es alta cuando el recall es elevado y la precisión es razonable.
- **AUC-ROC** que mide la capacidad del modelo para diferenciar correctamente entre empleados que se van y empleados que se quedan, independientemente del umbral de decisión elegido.

*El criterio principal fue minimizar los falsos negativos, maximizando la capacidad del modelo para detectar empleados que realmente abandonan la empresa.

Comparación de modelos entrenados

Modelo	Accuracy	Precisión	Recall	F1-score	AUC-ROC
Regresión Logística	—	—	—	—	—
XGBoost	0.816	0.431	0.468	0.449	0.771
Random Forest (modelo base)	0.823	0.451	0.489	0.469	0.785

Tabla 1: Comparación del rendimiento de los modelos en el conjunto de test (umbral 0.5)

Nota: El umbral 0.5 es el valor por defecto, pero no el óptimo para este problema de negocio. El modelo final (Random Forest Mejorado) se evaluó y ajustó con un umbral de 0.40, obteniendo un Recall del 68.1% (ver Tabla 2).

La Regresión Logística se utiliza en este trabajo como modelo baseline, sirviendo como punto de referencia inicial e interpretativo. Su objetivo principal es establecer un rendimiento base sobre el que comparar modelos más complejos, y facilitar la comprensión del comportamiento general del problema.

Los modelos basados en árboles (Random Forest y XGBoost) se emplean posteriormente para capturar relaciones no lineales y mejorar la capacidad predictiva, especialmente en términos de recall, métrica prioritaria en este contexto.

La evaluación con el umbral por defecto (0.5) situó a Random Forest como el modelo más robusto, con un Recall ligeramente superior (48.9% vs 46.8%). Sin embargo, la **detección de menos de la mitad de los casos reales era inaceptable para el negocio**. Por ello, se procedió a un **ajuste estratégico del umbral de decisión** del modelo Random Forest, priorizando maximizar el Recall. Este ajuste, analizado en la Tabla 2, es lo que llevó a la configuración final del modelo con un umbral de 0.40 y un Recall del 68.1%.

Selección e interpretación del modelo final

El modelo seleccionado corresponde a una versión optimizada de Random Forest, en la que se ajustaron los hiperparámetros y el umbral de decisión con el objetivo de maximizar el recall en un contexto operativo. Este modelo se seleccionó como solución final debido a:

- Un rendimiento en test con umbral 0.5 ligeramente superior en recall (48.9%) y F1-score (0.469) frente a XGBoost (46.8% y 0.449).
- Su capacidad para capturar relaciones no lineales entre las variables del dataset.
- Un equilibrio adecuado entre capacidad predictiva e interpretabilidad del modelo.

Configuración Operativa Final: El modelo recomendado para producción es el Random Forest con los hiperparámetros optimizados y, críticamente, con un **umbral de decisión de 0.40**. Esta configuración (cuyas métricas se detallan en la fila correspondiente de la Tabla 2) logra el equilibrio operativo deseado: detecta **7 de cada 10 casos reales de rotación** (Recall 68.1%) con una carga de intervención manejable (alertas para el 30.3% de la plantilla).

Trade-off de umbrales

Umbral	Recall	Precisión	Alertas	% Plantilla	Casos perdidos
0.50	44.7%	45.7%	46	15.6%	26
0.40 <i>* Recomendado</i>	68.1%	36.0%	89	30.3%	15
0.35	78.7%	33.6%	110	37.4%	10
0.30	87.2%	27.3%	150	51.0%	6

Tabla 2: Impacto del umbral de decisión en el rendimiento del sistema de alertas (RF Mejorado)

Los resultados de la Tabla 2 corresponden al **Random Forest Mejorado** (con hiperparámetros optimizados: `n_estimators=200`, `max_depth=15`), no al modelo base de la Tabla 1. Esto demuestra que la combinación de **optimización de hiperparámetros + ajuste de umbral** es lo que permite alcanzar los mejores resultados operativos.

Los resultados muestran claramente el trade-off existente entre recall, precisión y carga operativa del sistema de alertas. A medida que se reduce el umbral de decisión, el modelo es capaz de detectar un mayor porcentaje de empleados que realmente abandonarán la empresa, a costa de generar un mayor número de falsas alarmas.

Desde una perspectiva de recursos humanos, este comportamiento es aceptable, ya que el coste de no intervenir a tiempo sobre un empleado que abandona la empresa suele ser significativamente superior al coste de aplicar medidas preventivas a empleados que finalmente no se marchan.

El análisis de importancia de variables del modelo Random Forest confirmó los hallazgos del EDA, identificando factores como la sobrecarga laboral (horas extra), la antigüedad en

la empresa y el salario como predictores claves de rotación, lo que refuerza la relevancia de dimensiones psicosociales como el riesgo de burnout, el compromiso y la cultura organizacional.

Extracción de datos y predicción

La predicción se plantea como una herramienta preventiva aplicada durante el onboarding, concretamente a los tres meses de incorporación del empleado.

Este momento se considera óptimo porque:

- El empleado ya ha tenido contacto real con el puesto y la cultura.
- Se dispone de información relevante sobre carga laboral, expectativas y adaptación.
- Aún existe margen de actuación para intervenir antes de una decisión de abandono.

Para esta predicción se utilizará la **configuración final del modelo Random Forest con umbral 0.40**, garantizando la máxima detección preventiva.

Demo y aplicación práctica

Se ha preparado una demo interactiva para probar el modelo, orientada a simular su uso en un entorno real de RRHH.

La demo permite introducir información del empleado y obtener una estimación de riesgo de rotación, facilitando la comprensión y validación del modelo por perfiles no técnicos.

Acciones previstas según nivel de riesgo

Empleados de alto riesgo (>70%)

- Intervención prioritaria enfocada en reducción de desgaste y retención:
 - o Programa anti-burnout obligatorio
 - o Revisión de carga de trabajo con el manager
 - o Plan de desarrollo de carrera interno
 - o Mentoría 1:1

Empleados de riesgo medio (40–70%)

- Acciones preventivas de bajo coste:

- Encuesta de satisfacción específica
- Flexibilidad horaria opcional
- Reconocimiento de logros

Sistema de alertas

- Reporte semanal a RRHH: Top 10 empleados en riesgo
- Dashboard para managers: equipos con mayor riesgo
- Métricas mensuales del sistema:
 - % falsos positivos
 - % falsos negativos
 - Recall global del modelo

Limitaciones y futuros pasos

Limitaciones

- Uso de un dataset simulado (Kaggle).
- Variables proxy como aproximaciones a constructos complejos.
- El modelo identifica correlaciones, no causalidad.
- Predicciones dependientes de la calidad de los datos recogidos.

Futuros pasos

- Ajuste dinámico del umbral de decisión según estrategia de RRHH.
- Incorporación de datos temporales para modelar evolución del riesgo.
- Validación del modelo con datos reales de empresa.
- Evaluación de modelos adicionales con mayor interpretabilidad.
- Integración completa del sistema en herramientas internas de RRHH.

Conclusión

Este proyecto demuestra que en People Analytics, el valor de un modelo predictivo no se define únicamente por el algoritmo elegido, sino por su **ajuste estratégico a las necesidades del negocio**. El viaje desde un XGBoost inicial con sobreajuste hasta un Random Forest robusto, y el posterior **análisis y ajuste del umbral de decisión**, subrayan la importancia de priorizar métricas de impacto real (como el Recall) y de validar rigurosamente con datos no vistos. El resultado final es más que un clasificador: es

un **sistema de alerta temprana configurable** que traduce la predicción en acciones preventivas, permitiendo a RRHH intervenir proactivamente para retener talento crítico.