



Predicción de la Rotación de Personal mediante Machine Learning

De factores psicosociales a modelo predictivo aplicable a People Analytics

Contexto y Motivación

La rotación de personal representa un desafío crítico para las organizaciones, generando:

- **Costes** económicos directos e indirectos significativos.
- **Pérdida** de conocimiento institucional y experiencia.
- **Impacto negativo** en la moral y productividad del equipo.



Tradicionalmente, el análisis se ha centrado en **datos descriptivos**, que si bien útiles, **no permiten anticipar ni prevenir**.

El objetivo de mi proyecto es **trascender este enfoque** desarrollando un **modelo de Machine Learning capaz de predecir** la rotación antes de que ocurra.

Objetivos del Proyecto

Principal: Predecir Rotación

Desarrollar un modelo robusto que anticipe la probabilidad de que un empleado abandone la organización.

Secundario: Comparar Modelos ML

Evaluar y contrastar diferentes modelos de Machine Learning para identificar el más adecuado y preciso para esta tarea.

Secundario: Interpretar Variables Clave

Identificar y comprender los factores más influyentes que subyacen a la decisión de rotar, ofreciendo insights accionables.

Secundario: Proponer Acciones Estratégicas



Basándome en los resultados, formular recomendaciones concretas para implementar estrategias de retención de personal.




Fuentes de Datos: IBM HR Analytics Dataset

Para este estudio, he utilizado el dataset con el que realicé mi EDA (**IBM HR Analytics**) disponible en *Kaggle*, que me proporciona una base rica y diversa para la modelización:

- Volumen: **1.470 registros de empleados**.
- Riqueza: **35 variables** detalladas por empleado.
- Categorías de Variables: **Demográficas** (edad, género), **Laborales** (puesto, salario), **Psicosociales** (satisfacción, ambiente), y **Desempeño**.
- Desbalance de Clases: La tasa de rotación observada es del 16%, lo que **indica un desequilibrio** que debe gestionarse adecuadamente en el modelado.



EDA: Hallazgos Clave



Rotación No Aleatoria

La rotación no es un evento fortuito, sino influenciado por **patrones detectables**.



Horas Extra: Factor de Riesgo

Existe una correlación directa entre las horas extra y un **mayor riesgo de abandono**.



Bienestar y Engagement

Altos niveles de bienestar y engagement actúan como poderosos **factores protectores** contra la rotación.



Cultura Positiva

Una cultura organizacional que fomenta un ambiente positivo **reduce significativamente la propensión al abandono**.



Preprocesamiento de Datos y Feature Engineering

1



Raw Data

- **Dataset original**, heterogéneo y con posibles inconsistencias.
- **Dataset derivado de trabajo EDA** con la visión depurada.

2



Limpieza y Transformación

- Eliminación de valores nulos e irrelevantes.
- Conversión de variables categóricas con **One-Hot Encoding** y **drop='first'**.
- **Transformación de variables ordinales** respetando su escala original.
- **División estratificada** en conjuntos de entrenamiento y test.

3



Dataset listo para ML

- Dataset final listo para entrenamiento y evaluación de los modelos.

Definición del Problema de Clasificación

Clasificación Binaria: Attrition

Abandono: El empleado rotará (Attrition 1)

Permanencia: El empleado permanecerá en la empresa (Attrition 0)

Prioridad: Maximizar Recall

Recall

Que % de empleados que SI se van identifica el modelo

Dada la naturaleza del problema, mi **objetivo principal es detectar el mayor número posible de casos de rotación real**. Es decir, priorizo la minimización de los Falsos Negativos (FN).

- Costo de un Falso Negativo muy alto. Implica no detectar a un empleado en riesgo y, consecuentemente, perderlo, con el costo asociado de reemplazo y formación.
- Costo de un Falso Positivo relativamente bajo. Significa identificar a un empleado en riesgo que finalmente no rota. Se podrían aplicar acciones preventivas de retención innecesarias, pero el coste es menor que perder a un empleado valioso.


Falso Negativo

El modelo predice que el empleado NO se irá, pero en realidad SÍ abandona la empresa.

Falso Positivo


El modelo predice que el empleado SÍ se irá, pero en realidad NO abandona la empresa.

Parámetros utilizados

 = estrategias para tratar el desbalance

1 Pipeline profesional


Regresión Logística (baseline)


- ColumnTransformer & StandardScaler (escalado)
-  class_weight='balanced'
- max_iter=1000 (asegurar convergencia)

Random Forest

-  class_weight='balanced'
- n_estimators=100 (100 árboles)

XGBoost

-  scale_pos_weight
- n_estimators=100 (100 árboles)
- eval_metric='logloss' (classific binaria)


= **5.19** → cada caso positivo (Attrition=1) vale como 5.19 casos negativos.

2 **Validación** → Cross-validation estratificado para comparar modelos, no solo métricas en train.

3 **Optimización de hiperparámetros** → Uso de GridSearchCV con métrica F1 (la correcta para el problema).

4 **Análisis del trade-off** → La evaluación con distintos umbrales y el gráfico de compromiso entre Recall y Precision es de gran valor para el negocio.


5 **Feature Importance** → Interpretación correcta y coherente con el EDA.

Métricas utilizadas

- **Recall = Cuántos empleados que realmente se van detecta el modelo.**
En rotación, lo peor es no detectar a alguien que se va, porque no hay tiempo de intervenir.
- **Precision = Cuántas de las alertas que lanza el modelo ("se van") son realmente empleados que se van.**
Sirve para controlar el esfuerzo del equipo de RRHH.
- **F1-score = Equilibrio entre detectar muchos casos (recall) y no generar demasiadas alertas falsas (precision).**
Permite comparar modelos de forma justa en un problema desbalanceado como este.
- **Accuracy = Porcentaje total de aciertos.**
Aquí no es clave, porque la mayoría de empleados no rota y puede dar una falsa sensación de buen rendimiento.
- **AUC-ROC = Cómo de bien hace el modelo la separación entre empleados con riesgo y sin riesgo.**
Un valor muy alto indica que el modelo distingue muy bien ambos perfiles, aunque no es la métrica principal para negocio.

Proceso de modelado

El modelo más adecuado →



Entrenamiento inicial

01

- Pipelines iniciales
- Accuracy ~ 1.00 en entrenamiento (sobreajuste).

Estimación de rendimiento real

02

- Aplicación de **cross-validation** para estimar el rendimiento con datos nuevos.
- Random Forest y XGBoost no generalizaban adecuadamente.

Optimización de hiperparámetros

03

- **GridSearch** para encontrar los mejores ajustes del modelo y mejorar su rendimiento sin hacer pruebas manuales
- XGBoost mostró el mejor equilibrio en validación cruzada. **Lo elijo como mejor modelo en Train.**



Evaluación en conjunto de test

04

- **XGBoost en test, cayó** significativamente en recall (sobreajuste).
- **Random Forest mejoró** en test, detectando más casos reales de abandono.



Ajuste del umbral de decisión

05


- **Ajusté el umbral de decisión.**
- **Analicé el trade-off** entre recall, precisión y carga operativa del sistema..
- **Random Forest mostró el mejor resultado.**



Veamos mas en detalle

Estrenamiento inicial - PIPELINES

TRAIN



MODELO	ACCURACY	CUANTOS PREDICHOS	DE TOTALES	CONCLUSIONES
REGRESION LOGISTICA	0,777	376	1176	Accuracy alto
RANDOM FOREST	1	190	1176	Sobreajuste
XGBOOST	1	190	1176	Sobreajuste

 **REGRESION LOGISTICA**
Accuracy 0.777 | Predice  77.7% 376 empleados de 1.176 (190 reales) | Sobreestima los casos de rotación | Prefiere FP que FN.

 **RANDOM FOREST**
Accuracy: 1.000 | Predice  100% 190 empleados de 1.176 (190 reales) | Ha memorizado los datos en lugar de aprender patrones.


 `class_weight='balanced'`

 **XGBoost**
Accuracy: 1.000 | Predice  100% 190 empleados de 1.176 (190 reales) | Ha memorizado los datos en lugar de aprender patrones.

Veamos mas en detalle

Estimación de rendimiento real - Cross Validation

TRAIN



MODELO	ACCURACY	F1	PRECISION	RECALL	CONCLUSIONES
REGRESION LOGISTICA	0,747	0,486	0,365	0,737	Alto Recall y baja precisión, prefiere no perder casos reales... a costa de demasiados falsos positivos.
RANDOM FOREST	0,857	0,24	0,875	0,142	Mucha precisión, pero detecta muy pocos casos. No generaliza bien.
XGBOOST	0,866	0,483	0,643	0,389	Mejor precisión, pero pierde muchos casos reales. No generaliza bien.

REGRESION LOGISTICA
Accuracy: 0.747 | F1 mejor | Precision baja (muchos FP) | Recall muy alto (detecta 73,7%). → Prefiere no perder casos reales.


RANDOM FOREST
Accuracy: 0.857 | F1 peor | Precision muy alta | Recall muy bajo (detecta 14,2%).

XGBoost
Accuracy: 0.866 | F1 casi como RL | Precision mejor | Recall bajo (pierde casos reales).

Veamos mas en detalle

Optimización de hiperparámetros - GridSearch

TRAIN



MODELO	ACCURACY	F1	PRECISION	RECALL	AUC-ROC	CONCLUSIONES
REGRESION LOGISTICA	0,901	0,606	0,841	0,474	0,872	La mayor precisión (84%), pero recall muy bajo (47%).
RANDOM FOREST	0,886	0,682	0,621	0,758	0,913	Mejor equilibrio con 76% de recall.
XGBOOST	0,94	0,825	0,777	0,879	0,978	El mejor recall y accuracy. Lo elijo como mejor modelo en TRAIN.

 **REGRESION LOGISTICA**

Aunque casi siempre acierta cuando dice que alguien se va, se le escapan más de la mitad de los casos reales.

 **RANDOM FOREST**

Aunque presenta mejor equilibrio, sigue sin detectar 46 casos y una precisión menor (62%).

 **XGBoost**

Retendría a 167 empleados | Perdería 23 empleados | Intervendría en 215 empleados de 167 que realmente las necesitan.



Veamos mas en detalle

Evaluación **TEST**



Comienzo comparando las métricas de XGBoost en Train y en Test

MODELO	COMPARACION	ACCURACY	F1	PRECISION	RECALL	AUC-ROC	CONCLUSIONES
XGBOOST	TRAIN	0,94	0,83	0,777	0,879	0,978	Mejor modelo probado en Train. Recall cae a 46.8% → modelo no generaliza: overfitting.
	TEST	0,816	0,449	0,431	0,468	0,771	Parece que el modelo memorizó patrones de entrenamiento, pero no aprendió relaciones generales.



Mi corazón, roto.

Veamos mas en detalle

Evaluación **TEST**



... voy a probar con otro modelo más robusto a ver qué pasa

MODELO	CONJUNTO	ACCURACY	F1	PRECISION	RECALL	AUC-ROC	CONCLUSIONES
RANDOM FOREST	TRAIN	0,886	0,68	0,621	0,758	0,913	
	TEST	0,823	0,469	0,451	0,489	0,785	Detecta 23 de 47 empleados que se van, se escapan 24 empleados. Se intervendría con 28 empleados que no se van. Detecta 49% de los casos reales.


Veamos mas en detalle

Evaluación **TEST**



... comparo los resultados de RF y XGBoost en Test a ver que encuentro

MODELO	PRIMERA ESTRATEGIA	ACCURACY	F1	PRECISION	RECALL	AUC-ROC	CONCLUSIONES
XGBOOST	TEST	0,816	0,449	0,431	0,468	0,771	25 Falsos negativos (se escapan sin detectar)
RANDOM FOREST	TEST	0,823	0,469	0,451	0,489	0,785	24 Falsos negativos (se escapan sin detectar)



Voy hacia **Random Forest**




Veamos mas en detalle

Evaluación

TEST

04



Veamos mas en detalle


Evaluación **TEST**



... optimizo los parámetros de RF con un pipeline mejorado en umbral de 0.5 a ver si lo puedo mejorar

MODELO	PRECISION	RECALL	CONCLUSIONES
RANDOM FOREST MEJORADO	0,457	0,447	Comparado con el primer RF, no hay mejora . 48.9% → 44.7%

... de nuevo



Veamos mas en detalle

Evaluación **TEST**

05

La elección más **sostenible** →

Recall 68.1%:
Detecta 32 de los 47 reales

Carga 30.3%
89 intervenciones (sostenible)


Precisión 36.0%
1 de cada 2.8 alertas es correcta

Casos perdidos
15 empleados no detectados

... no mejora, así que voy a intentar ver rendimiento en diferentes umbrales. Trade-off

MODELO	UMBRALES	PRECISION	RECALL	CONCLUSIONES
RANDOM FOREST Puedo observar qué ocurre con las métricas cuando cambia el umbral	0.5	0,457	0,447	
	0,4	0,36	0,681	Recall 68.1% → detecta 32 de 47 casos Precisión 36.0% Intervenciones: 89 empleados (30.3% de plantilla) Casos perdidos: 15 ~3 de cada 4 casos detectados, carga de trabajo razonable
	0,35	0,336	0,787	Recall 78.7% → detecta 37 de 47 Precisión: 33.6% Intervenciones: 110 empleados (37.4% de la plantilla) Casos perdidos: 10 Más detección, pero casi 40% de la plantilla a gestionar
	0,3	0,273	0,872	Recall: 87.2% → detecta 41 de 47 Precisión: 27.3% Intervenciones: 150 (51.0% de la plantilla) Casos perdidos: 6 Máxima cobertura, pero más de la mitad de la plantilla a gestionar

Trade-off: Recall vs Precisión



¿Por qué el umbral 0.40?


Maximiza la detección de casos reales **manteniendo una carga operativa sostenible** (~30% de la plantilla).

Umbrales más bajos incrementan el recall, pero **generan un volumen de intervenciones difícilmente asumible** por RRHH.

Interpretación del Modelo y Factores Clave

Factores Más Influyentes en la Rotación (Random Forest):

- **Salario y Satisfacción Salarial:** Variables económicas fundamentales en la decisión de permanecer o no.
- **Antigüedad en la Empresa:** Tanto una antigüedad muy corta como excesivamente larga pueden ser indicadores.
- **Horas Extra:** El factor con mayor peso, incrementando significativamente el riesgo de abandono.
- **Engagement:** Un bajo nivel de compromiso es un fuerte predictor de rotación.
- **Riesgo de Burnout:** Una alta probabilidad de agotamiento profesional aumenta la propensión al abandono.



La visualización de la importancia de las variables confirma la relevancia de factores psicosociales y laborales.



Aplicación Práctica en People Analytics

Uso Preventivo

Probabilidad de rotación.

A los 3 meses de incorporación del empleado, permitiendo intervenciones tempranas.

Demo Interactiva

Simulador el riesgo de rotación por empleado.

Variables como BurnoutRisk, CulturaPositiva o JobSatisfaction son proxies basadas en encuestas. En producción, los datos del HRIS complementarán estas señales.

Sistema de Alertas Dinámico

Nivel de riesgo por modelo ML

-  Alto (>70%): Intervención intensiva.
Anti-burnout | Revisión cargas | Planes | Mentorías
-  Medio (40-70%): Prevención estructurada.
Encuesta | Flexibilidad | Reconocimiento
-  Bajo (<40%): Seguimiento normal
Seguimiento | Engagement | Encuesta

Señales tempranas

Basadas en reglas de negocio, como



Burnout elevado

que pueden activar acciones preventivas incluso cuando el riesgo global es bajo


Limitaciones y Próximos Pasos

Limitaciones Actuales

- El dataset actual es simulado, lo que puede no reflejar la complejidad de un entorno real.
- Utilización de variables proxy, lo que podría no capturar la esencia completa de los fenómenos a medir.
- Distinción crucial entre correlación y causalidad; el modelo identifica patrones, no necesariamente causas directas.

Futuros Pasos Estratégicos

- Desarrollo de un ajuste dinámico del umbral de predicción para mayor precisión y adaptabilidad.
- Incorporación de datos temporales reales y validación exhaustiva en una empresa operativa.
- Integración fluida del modelo en las herramientas y plataformas existentes del departamento de RRHH.



Conclusión



Valor Estratégico del Proyecto

Este modelo representa una integración fundamental de la analítica de datos en la toma de decisiones estratégicas de RRHH, transformando la gestión del talento.



Sistema de Alerta Temprana Adaptable

Es un sistema de alerta temprana flexible, capaz de adaptarse a las cambiantes estrategias de RRHH y a las necesidades específicas de la organización.



Medición del Éxito

El verdadero éxito se medirá por la capacidad del equipo de RRHH de anticipar el abandono de empleados y guiar acciones preventivas efectivas, mejorando la retención de talento.

Eskerrik asko!
Gracias!